A CLEAN PROOF FOR DUELING BANDITS

从成对偏好到置信上界

Contextual Dueling Bandits

第 1–4 节 · 约 10 分钟 · v1

01
问题设定
2 分 10 秒

02
假设
2 分 10 秒

03
算法
2 分 30 秒

04
置信界
2 分 30 秒

目录

四个问题，串起从偏好反馈到置信上界的逻辑。

01 **Problem Setup: Contextual Dueling Bandits** — 03–04 页
观察什么：候选特征、成对偏好与遗憾 — 2 分 10 秒

02 **Assumptions** — 05–06 页
依赖什么：有界性与局部曲率下界 — 2 分 10 秒

03 **Algorithm: Ridge-MLE Dueling UCB** — 07–09 页
怎样选择：参数估计、贪心第一臂与 UCB 第二臂 — 2 分 30 秒

04 **Confidence Bound** — 10–12 页
为何可信：参数置信椭球与效用差置信界 — 2 分 30 秒

每轮比较两个候选，只收到一个偏好标签

Contextual：候选带有特征，决策集合也可以随轮次变化。

1 观察候选集合

$$\mathcal{X}_t \subseteq \mathbb{R}^d$$

每个候选由特征 x 表示

2 选择一对候选

$$x_{t,1},\ x_{t,2} \in \mathcal{X}_t$$

例如：两条待比较的推荐

3 观察偏好结果

$$y_t \in \{0, 1\}$$

y = 1：第一个候选胜出

不可直接观测的效用 $f(x) = \langle \theta^\star, x \rangle$

比较使用差分特征 $\tilde{x}_t = x_{t,1} - x_{t,2}$

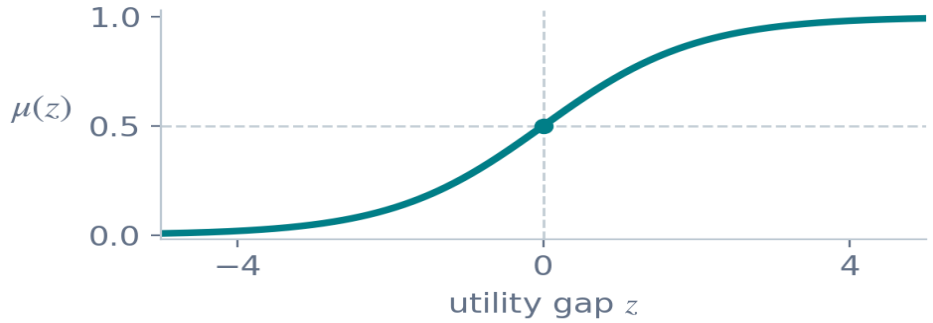
用效用差建模偏好，用遗憾衡量选择

胜率描述反馈机制；遗憾描述我们最终希望优化的目标。

LOGISTIC / BTL 反馈

$$\Pr(y_t = 1 \mid \mathcal{F}_{t-1}) = \mu(\langle \theta^\star, \tilde{x}_t \rangle)$$

$$\mu(z) = \frac{1}{1+e^{-z}}$$



效用相同：胜率 1/2；效用越高：越可能胜出。

优化目标：两个候选都接近最优

$$x_t^\star \in \arg\max_{x \in \mathcal{X}_t} f(x)$$

单步遗憾 = 两个候选各自的效用损失

$$r_t = [f(x_t^\star) - f(x_{t,1})] + [f(x_t^\star) - f(x_{t,2})]$$

$$R_T = \sum_{t=1}^{T} r_t$$

有界性控制尺度：先约束特征与真实参数

这些界会分别进入曲率控制、设计矩阵上界和正则化偏差。

给定的尺度约束

$$\|x\|_2 \le 1$$ 候选特征有界

$$\|\theta^\star\|_2 \le S$$ S 是已知常数

推得差分特征与真实得分有界

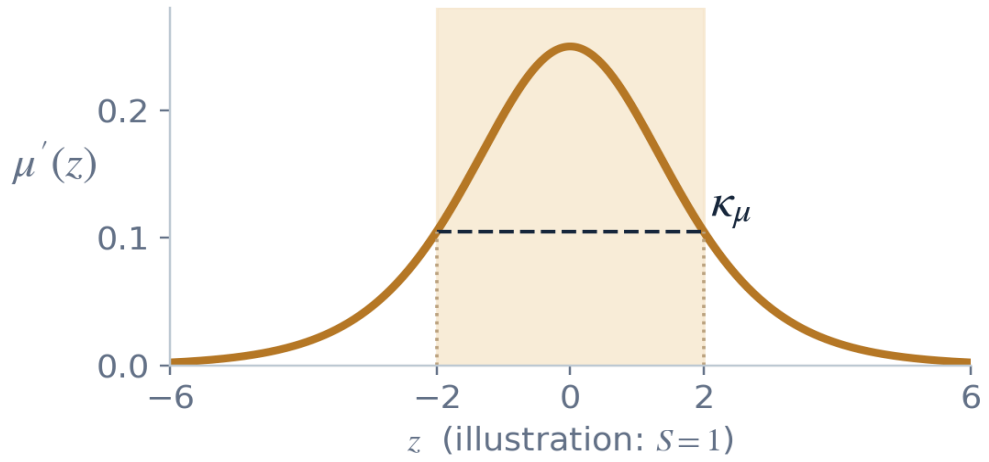
$$\|\tilde{x}_t\|_2 \le \|x_{t,1}\|_2 + \|x_{t,2}\|_2 \le 2$$

$$|\langle \theta^\star, \tilde{x}_t \rangle| \le 2S$$

直观作用 限定真实效用的范围，并为后续的误差控制提供尺度。

曲率下界把预测变化连接到参数误差

Logistic 曲线在两端变平；证明需要在相关区间内保留足够的曲率。



ASSUMPTION 2

$$\mu'(z) = \mu(z)(1-\mu(z)) \geq \kappa_\mu > 0$$

证明实际用到的中间点：

$$\xi_{s,t} \text{ between } \langle \theta^\star, \tilde{x}_s \rangle \text{ and } \langle \hat{\theta}_t, \tilde{x}_s \rangle$$

适用范围

仅有 θ⋆ 有界还不够：也需保证上述中间点处的曲率下界。
以下置信界以这一范围条件成立为前提。

把偏好标签转成带正则项的逻辑回归

用前 t−1 轮数据，估计第 t 轮使用的参数。

1 单次比较的负对数似然

预测得分 $z = \langle \theta, \tilde{x}_s \rangle$

$$\ell(y, z) = -y \log \mu(z) - (1 - y) \log(1 - \mu(z))$$

2 累加损失，再加入岭正则

$$\hat{\theta}_t = \arg\min_{\theta \in \mathbb{R}^d} \left\{ \sum_{s<t} \ell(y_s, \langle \theta, \tilde{x}_s \rangle) + \frac{\lambda}{2} \|\theta\|_2^2 \right\}$$

λ > 0 使目标严格凸、稳定参数估计；同时在置信界中产生一项偏差。

一阶条件是置信界证明的起点

Logistic 的特殊结构，让损失导数简化为“预测概率 − 实际标签”。

对得分求导

$$\frac{\partial \ell(y,z)}{\partial z} = \mu(z) - y$$

对参数求梯度

$$\nabla_\theta \ell(y_s, \langle \theta, \tilde{x}_s \rangle) = [\mu(\langle \theta, \tilde{x}_s \rangle) - y_s]\tilde{x}_s$$

最小点满足

$$\sum_{s<t} [\mu(\langle \hat{\theta}_t, \tilde{x}_s \rangle) - y_s]\tilde{x}_s + \lambda \hat{\theta}_t = 0$$

原稿 §3.2，p.4；式 (9)(10)

先选当前最优，再选值得比较的挑战者

Ridge-MLE Dueling UCB：第一臂利用当前估计，第二臂借助不确定性探索。

第一臂：预测效用最高

$$x_{t,1} \in \arg\max_{x \in \mathcal{X}_t} \langle \hat{\theta}_t, x \rangle$$

第二臂：相对第一臂的 UCB 最大

$$x_{t,2} \in \arg\max_{x \in \mathcal{X}_t} \{ \langle \hat{\theta}_t, x - x_{t,1} \rangle + b \, \| x - x_{t,1} \|_{V_{t-1}^{-1}} \}$$

每轮维护的信息

$$V_0 = \frac{\lambda}{\kappa_\mu} I_d$$

收到偏好后更新

$$V_t = V_{t-1} + \tilde{x}_t \tilde{x}_t^\top$$

b 的数值由下一部分的置信界确定。

置信椭球：一次高概率事件，覆盖所有轮次

先明确要证明什么，再看误差如何被噪声与正则化项控制。

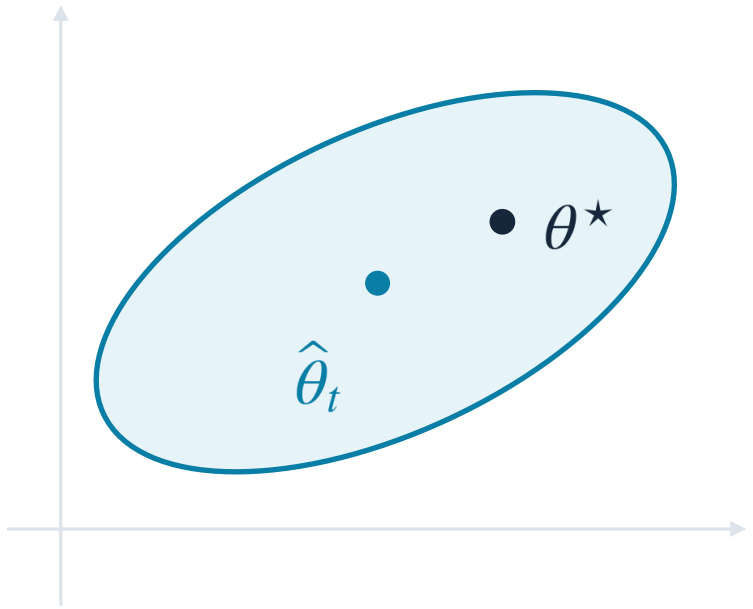
以至少 1−δ 的概率，对所有 t ≤ T 同时成立：

$$\|\hat{\theta}_t - \theta^\star\|_{V_{t-1}} \le \frac{\beta_T}{\kappa_\mu} = b$$

$$\|u\|_V = \sqrt{u^\top V u}$$

V 决定椭球形状，b 决定整体尺度。

δ 是失败概率；保证覆盖整个时间段。



参数空间中的置信区域（示意）

证明骨架：先把误差拆成噪声与正则偏差

$$\Delta_t = \widehat{\theta}_t - \theta^\star \qquad \varepsilon_s = y_s - \mu(\langle \theta^\star, \tilde{x}_s \rangle), \quad \mathbb{E}[\varepsilon_s \mid \mathcal{F}_{s-1}] = 0, \quad |\varepsilon_s| \le 1$$

1 驻点等式 + 均值定理

$$H_t \Delta_t = N_t - \lambda \theta^\star \qquad N_t := \sum_{s<t} \varepsilon_s \tilde{x}_s$$

2 曲率给下界

$$H_t = \sum_{s<t} \mu'(\xi_{s,t}) \tilde{x}_s \tilde{x}_s^\top + \lambda I_d \succeq \kappa_\mu V_{t-1}$$

3 柯西施瓦茨 + 消去误差范数

$$\|\Delta_t\|_{V_{t-1}} \le \frac{1}{\kappa_\mu} \left(\|N_t\|_{V_{t-1}^{-1}} + \sqrt{\lambda \kappa_\mu}\, S \right)$$

噪声有了上界，UCB 的探索项就确定了

自归一化不等式控制自适应数据的噪声；加权柯西施瓦茨把参数界转成效用差界。

置信半径 = 正则化偏差 + 噪声上界

$$\beta_T = \sqrt{\lambda \kappa_\mu}\, S + \sqrt{2\log(1/\delta) + d\log\left(1 + \frac{4\kappa_\mu T}{\lambda d}\right)}, \qquad b = \frac{\beta_T}{\kappa_\mu}$$

对任意候选对 x, x′，同时成立：

$$|f(x) - f(x') - \langle \hat{\theta}_t, x - x' \rangle| \le b \, \|x - x'\|_{V_{t-1}^{-1}}$$

因此 预测的效用差 + 置信半径，就是第二个候选使用的 UCB。

把四部分接成一条线

从一次偏好反馈，走到一次有置信保证的比较。

01

问题

成对比较
只观察偏好

→

02

假设

控制尺度
保留局部曲率

→

03

算法

Ridge-MLE 估计
贪心 + UCB 选臂

→

04

置信界

参数误差界
推出效用差上界

核心连接：置信界给出探索项，探索项指导下一轮比较。